Alfabetização no Brasil: contexto e metas

Dados oficiais, validação temporal e contexto territorial para apoiar decisões educacionais.

Uma análise de risco por aluno e de metas por município.

Risco = não alfabetizado. Predição contextual; não é diagnóstico individual.

Kevin Barreto da Silva · RM 374637

Dados e perguntas da análise

2023–2025

Avaliações estaduais de alfabetização

2021 / 2022

Contexto socioeconômico e populacional

Metas

Comparação na rede e no ano corretos

Quais contextos concentram risco e quais municípios merecem análise prioritária?

Fontes: INEP AEEB 2023–2025; metas oficiais; INSE 2021; IBGE Censo 2022.

Kevin Barreto da Silva · RM 374637

Treino em 2024, teste em 2025

2023 → 2024

Contexto anterior e desenvolvimento

80% / 20%

Municípios para ajuste e reserva

2024 → 2025

Contexto anterior e teste final

O teste não escolhe o modelo, os atributos ou o limiar.

Backtest retrospectivo com as versões disponíveis das fontes; sua disponibilidade nas datas históricas não foi verificada.

Atributos usados na previsão

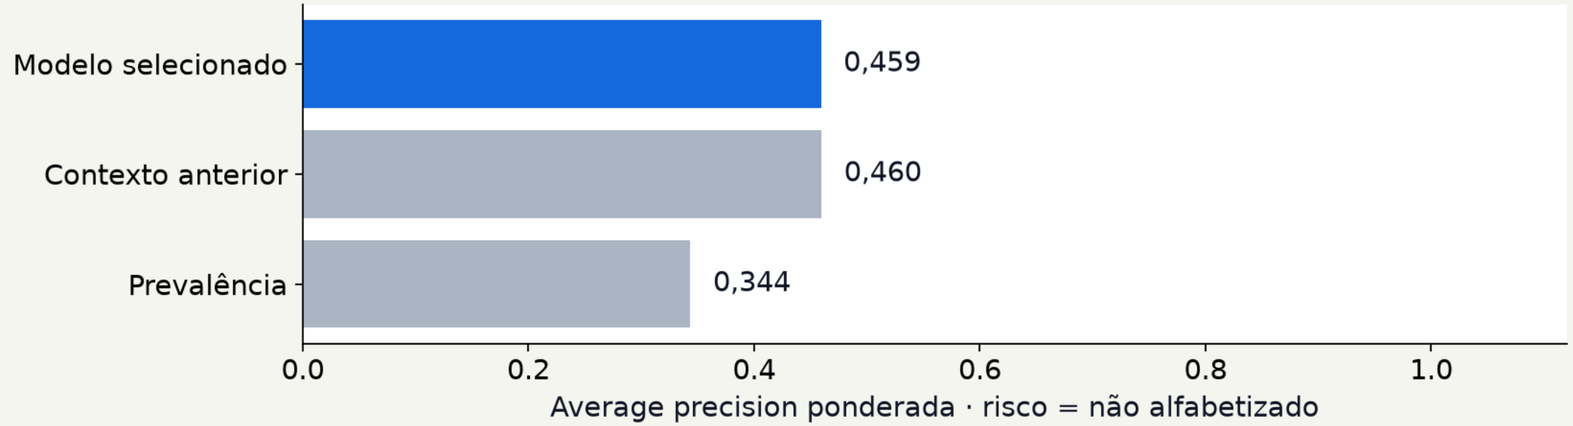
- Histórico municipal do ano anterior.
- Rede, território e contexto socioeconômico.
- População e densidade demográfica.

Alunos com os mesmos atributos podem receber o mesmo risco.

Maior importância nesta execução: Média de português no ano anterior, Alfabetização no ano anterior, Unidade da Federação.

Proficiência individual, respostas e resultados contemporâneos ficam fora dos atributos preditivos.

Classificação: comparação com o baseline



Teste 2025. Mesma população e pesos em todas as comparações disponíveis.

AP semelhante ao baseline contextual; não houve ganho demonstrado. Modelo: 0,4591; baseline: 0,4596. Diferença observada: -0,000483; IC 95%: [-0,002943; 0,001808].

Modelo selecionado na validação: random_forest. Maior average precision é melhor.

Recall, precisão e seletividade

98,0%
Recall de não alfabetizados

35,8%
Precisão das sinalizações

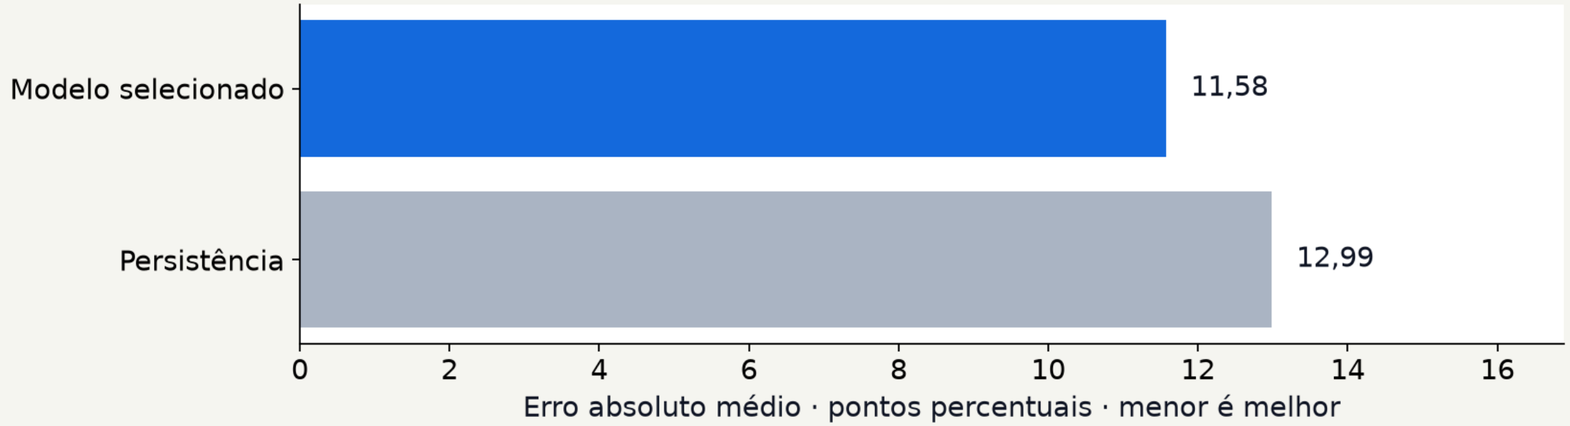
0,185
Limiar escolhido na reserva

O limiar F2 sinaliza 93,56% dos registros (contagem sem pesos). A baixa seletividade exige avaliar a capacidade de atendimento.

Recall e precisão ponderados descrevem erros diferentes; o limiar F2 não demonstra benefício de uma intervenção.

Teste 2025; métricas ponderadas. A regra de limiar foi fixada antes de avaliar o teste.

Previsão das taxas municipais



Teste 2025. Rede municipal; peso igual por município.

Modelo municipal: hist_gradient_boosting. O erro é medido em pontos percentuais, com o mesmo peso para cada município.

Rede municipal; uma linha por município e ano. Probabilidade individual não é taxa municipal prevista.

Municípios com maior déficit projetado

Código IBGE	UF	Projeção 2026	Meta	Diferença
4319604	RS	44,3%	>= 80,0%	-35,7 p.p.
4304507	RS	45,5%	>= 79,8%	-34,3 p.p.
4304408	RS	48,2%	>= 79,2%	-31,1 p.p.
4314209	RS	42,7%	>= 73,4%	-30,7 p.p.
4317707	RS	45,9%	>= 76,4%	-30,5 p.p.

A diferença entre projeção e meta organiza os municípios para investigação e conferência local.

Projeção 2026 após reajuste. As métricas de teste 2025 pertencem ao modelo avaliado, preservado separadamente.

Perfis territoriais semelhantes

Cluster	Região	Municípios
2	Nordeste	1445
1	Sudeste	909
1	Sul	778
0	Sudeste	531
2	Norte	342

Composição descritiva: 19 pares cluster/região; até cinco maiores acima. Perfis e UF completos no suplemento.

cluster 1: 2.313 municípios, taxa observada 81,9%; cluster 2: 2.034 municípios, taxa observada 64,8%. Associação descritiva, sem inferência causal.

Clusterização descritiva após congelar a avaliação. Semelhança não demonstra efeito causal.

Metas de 2027–2030 sob taxa constante

Ano	Atingem	Não atingem	Sem meta	Sem projeção
2027	3016	2319	165	0
2028	2615	2720	165	0
2029	2191	3144	165	0
2030	1749	3586	165	0

Hipótese: manter a taxa prevista de 2026. Sem novo treino nem garantia futura; usar para investigar distância às metas.

2027–2030: cenários explícitos frente às metas, sem garantia de desempenho futuro. Risco = não alfabetizado. Predição contextual; não é diagnóstico individual.

Kevin Barreto da Silva · RM 374637